Аналитический отчёт: Кластеризация абонентов сотового оператора

1. Введение и постановка задачи

Задача — сегментация абонентов сотового оператора на основе их онлайн-активности с целью персонализации предложений и сервисов. Предполагается, что различные группы пользователей имеют выраженные поведенческие паттерны (предпочтения категорий сайтов), которые можно использовать для таргетированных рекомендаций.

Подход: Применены два алгоритма — KMeans и HDBSCAN — с последующим сравнением качества и интерпретацией результатов.

---

2. Описание данных

2.1 Состав датасета

Файл	Строк	Признаки	Назначение
`activity.csv`	1 200 000	`client_id`, `website`	Посещения сайтов абонентами
`clients.csv`	50 000	`id`, `age`, `gender`, `region_id`	Демографический профиль
`websites.csv`	1 251	`website`, `category_id`	Категоризация сайтов
`categories.csv`	30	`id`, `name`	Справочник категорий
`regions.csv`	23	`id`, `name`	Справочник регионов

2.2 Качество данных

Проблема	Описание	Масштаб

Дубликаты в `activity`	Повторные пары `(client_id, website)` Дубликаты не убирали, так как это можно интерпретировать как повторное посещение сайта.	90 676 строк (7,6%)
Пропуски в `clients.gender`	Отсутствует пол	82 записи (0,16%), заполнены меткой «U»
Неоднозначная категоризация	208 сайтов имеют две категории. Так как здесь имеется неоднозначность, ввели веса посещений в зависимости от количества категорий сайта - 1 / N категорий	16,6% сайтов
Клиенты без активности	Абоненты, для которых нет данных о посещениях	9 350 чел. (18,7%), исключены

В исследуемом датасете были удалены 10% самых активных и самых неактивных пользователей, в том числе пользователи без активности. После очистки в анализе участвовали **33 446 абонентов**.

2.3 Статистика по абонентам

- **Возраст:** 16–80 лет, медиана — 35 лет, среднее — 35,3 года
- **Пол:** 52% женщин (F), 47,8% мужчин (M), 0,2% не указано
- **Регионы:** 23 региона, наиболее представлены центральные

2.4 Признак синтетичности данных

Данные являются синтетическими, что подтверждается несоответствием названий сайтов и присвоенных им категорий:

Сайт	Ожидаемая тематика	Присвоенная категория
`apteka-deal.online`	Аптека / Здоровье	Спорт и активный отдых
`aptekamarket.shop`	Аптека / Здоровье	Авто и мото
`avto-2456.io`	Авто	Образование
`bank-now56.ru`	Финансы	Ювелирные изделия

baby-beauty.com	Детские товары / Красота	Образование + Развлечения

Категории присвоены случайным образом, без логической связи с именем домена. Кроме того, у некоторых сайтов имеющих 2 категории, категории кажутся не сочетаемыми между собой и доменом в реальной жизни, например сайт **nova-expert.online** имеет категории *Каршеринг и такси* и *онлайн-кинотеатр.*

Также было исследовано распределение демографических признаков пользователей по каждой категории:

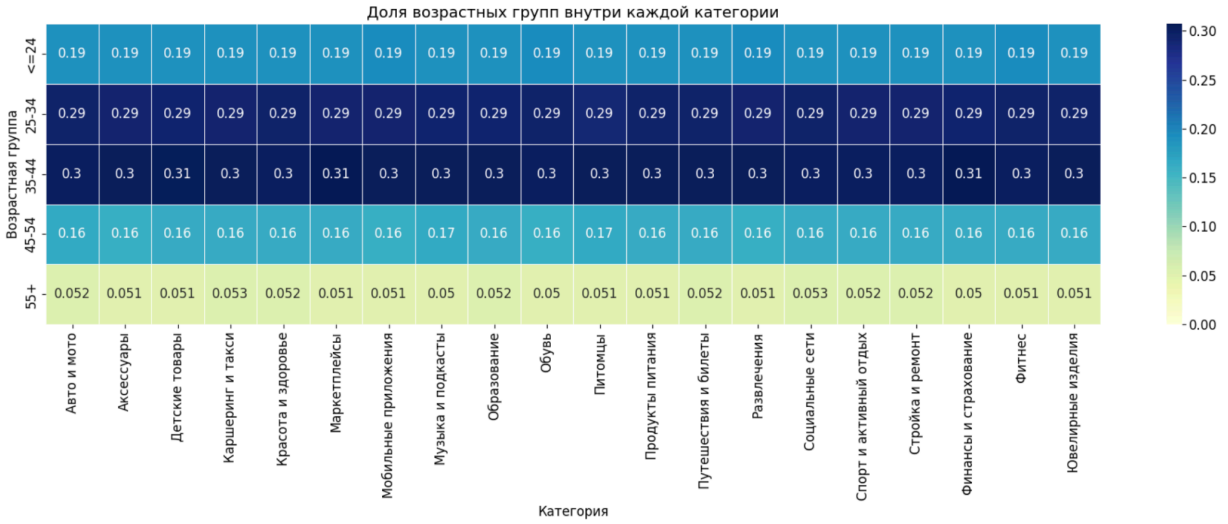

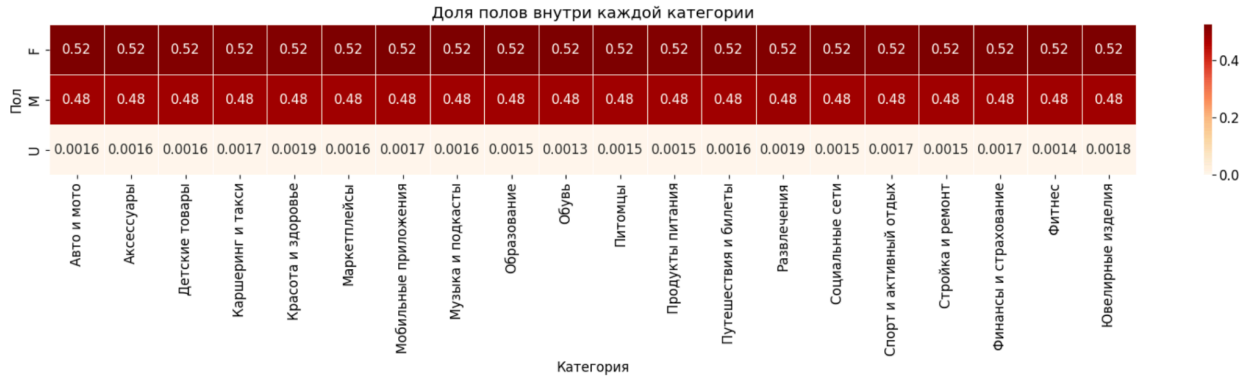

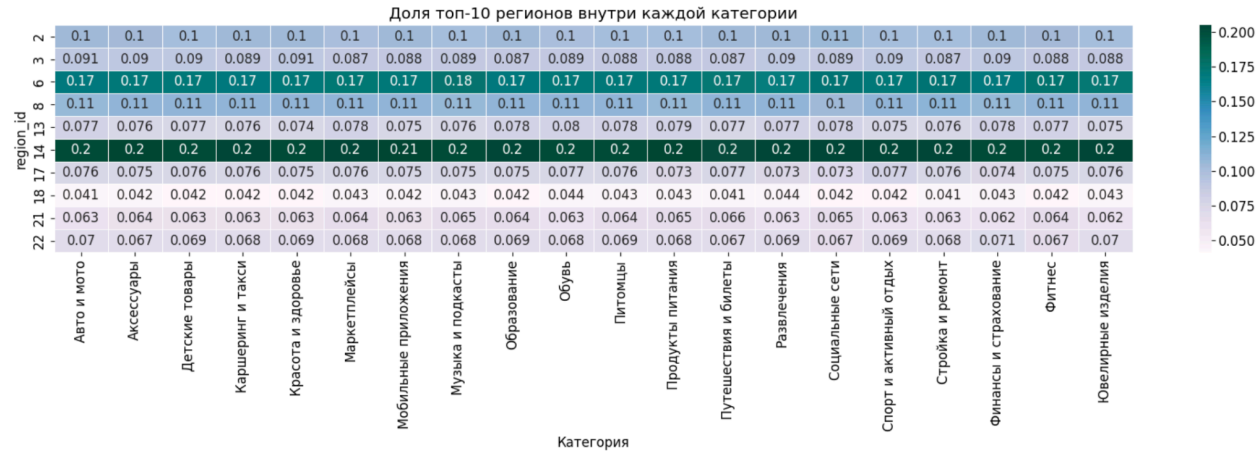

Как видно на графиках, демографические признаки распределены абсолютно одинаково во всех категориях.

3. Используемые алгоритмы

Для решения задачи сегментации были использованы 2 алгоритма кластеризации - KMeans и HDBSCAN (для сравнения результатов).

3.1 PCA (Principal Component Analysis)

PCA — метод линейного снижения размерности. Алгоритм находит новые оси (главные компоненты) в пространстве признаков таким образом, что первая компонента объясняет максимальную долю дисперсии данных, вторая — максимальную из оставшейся, и так далее.

Зачем применяется перед кластеризацией:

- Устраняет мультиколлинеарность между признаками
- Снижает вычислительную сложность
- Уменьшает влияние шума в исходных данных
- Позволяет визуализировать данные в 2D/3D

3.2 KMeans

KMeans — итерационный алгоритм разбиения данных на ровно **k** кластеров. Работает следующим образом:

1. Случайно инициализируются **k** центроидов
2. Каждая точка приписывается к ближайшему центроиду (по евклидову расстоянию)
3. Центроиды пересчитываются как среднее всех точек своего кластера
4. Шаги 2–3 повторяются до сходимости

Критерий оптимизации — минимизация суммарного квадратичного расстояния от точек до центроидов своего кластера (inertia):

```
Inertia = Σ Σ ||x - μ_k||²
```

Метрики качества:

- **Silhouette Score** — насколько точка ближе к своему кластеру, чем к ближайшему чужому. Диапазон: [−1, 1]. Хорошо: > 0,5; плохо: < 0,2
- **Elbow (Inertia)** — при правильном k на графике inertia от k виден «локоть»

3.3 HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise)

HDBSCAN — алгоритм кластеризации на основе плотности. В отличие от KMeans, не требует задавать количество кластеров и умеет работать с произвольной формой групп. Алгоритм состоит из следующих шагов:

1. **Вычисление расстояний достижимости** — для каждой точки рассчитывается расстояние до k ближайших соседей (core distance)
2. **Построение минимального остовного дерева** — точки соединяются по взаимным расстояниям достижимости
3. **Иерархическая кластеризация** — дерево конденсируется в иерархию кластеров (дендрограмма)
4. **Извлечение стабильных кластеров** — из иерархии выбираются наиболее устойчивые (стабильные по плотности) кластеры
5. **Шум** — точки, не вошедшие ни в один достаточно плотный кластер, получают метку **−1**

Метрики качества:

- **Silhouette Score** — аналогично KMeans, но важно считать по **всем** точкам, включая шум
- **Calinski-Harabasz Index** — отношение разброса между кластерами к разбросу внутри; выше = лучше
- **Davies-Bouldin Index** — среднее отношение внутрикластерного разброса к расстоянию между центроидами; ниже = лучше

---

4. Построение признакового пространства

3.1 Поведенческие признаки

Для каждого абонента построен вектор из 30 числовых признаков — нормализованная частота посещений сайтов каждой категории:

```
частота(абонент, категория) = количество_посещений_категории /
общее_количество_посещений
```

После нормализации применён `StandardScaler`. Итоговая матрица: **33 446 × 30**.

Топ категорий, использованных в анализе:

Спорт и активный отдых, Ювелирные изделия, Каршеринг и такси, Аксессуары, Стройка и ремонт, Образование, Мобильные приложения, Питомцы, Детские товары, Путешествия и билеты, Красота и здоровье, Маркетплейсы

3.2 Снижение размерности (PCA)

Для KMeans применён PCA:

Компонент	Накопленная объяснённая дисперсия
15 компонент	**58,6%**

Низкий процент объяснённой дисперсии при 15 компонентах из 30 указывает на **отсутствие выраженных направлений вариации** в данных — признак равномерно распределённого, слабоструктурированного пространства.

---

6. Кластеризация KMeans

4.1 Подбор числа кластеров

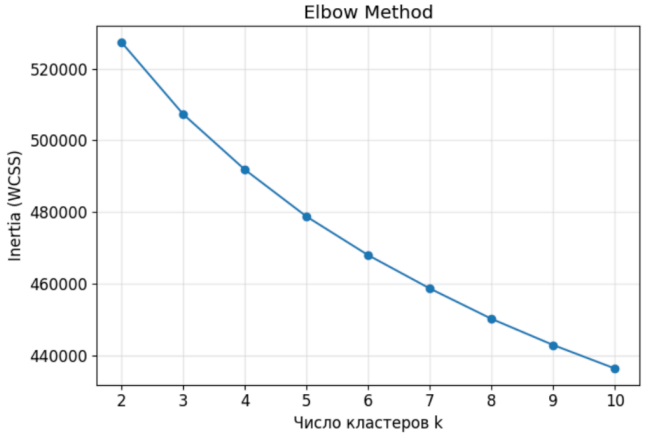

На графике Elbow-кривой отсутствует явный «локоть» — inertia снижается линейно, без выраженного перегиба. Silhouette монотонно падает после k=2 и стабилизируется на уровне ~0,04, не демонстрируя пика. Выбрано **k=5** без всяких оснований, просто чтобы кластеров было не 2.

4.2 Распределение абонентов по кластерам

Ниже приведены отклонения от среднего по всем абонентам (в долях частоты посещений).

Кластер 0 — «Активный образ жизни» (5 063 чел.)

Повышенный интерес	Δ	Пониженный интерес	Δ
Спорт и активный отдых	+0,040	Недвижимость	−0,013
Ювелирные изделия	+0,033	Фитнес	−0,011
Каршеринг и такси	+0,026	Одежда	−0,010

Кластер 1 — «Цифровой досуг» (9 068 чел.)

Повышенный интерес	Δ	Пониженный интерес	Δ
Дом и сад	+0,011	Недвижимость	−0,015
Социальные сети	+0,010	Фитнес	−0,010
Игры	+0,009	Спорт и активный отдых	−0,009

Кластер 2 — «Здоровье и питание» (6 492 чел.)

Повышенный интерес	Δ	Пониженный интерес	Δ
Фитнес	+0,030	Недвижимость	−0,011
Продукты питания	+0,026	Дом и сад	−0,007
Обувь	+0,005	Новости и СМИ	−0,007

Кластер 3 — «Информация и кафе» (6 562 чел.)

Повышенный интерес	Δ	Пониженный интерес	Δ
Кафе и рестораны	+0,030	Недвижимость	−0,008
Новости и СМИ	+0,029	Спорт и активный отдых	−0,008

Книги и канцелярия	+0,010	Ювелирные изделия	−0,006

Кластер 4 — «Недвижимость и медиа» (6 261 чел.)

Повышенный интерес	Δ	Пониженный интерес	Δ
Недвижимость	+0,053	Спорт и активный отдых	−0,007
Одежда	+0,009	Кафе и рестораны	−0,006
Онлайн-кинотеатры	+0,005	Ювелирные изделия	−0,005

4.3 Оценка качества KMeans

Метрика	Значение	Интерпретация
Silhouette (k=5)	**0,040**	Крайне плохо (норма > 0,5)
Silhouette (k=2)	**0,129**	Лучший результат, но всё равно слабый
Объясненная дисперсия PCA	**58,6%**	Нет явной структуры

Вывод: Низкие значения Silhouette свидетельствуют об отсутствии четко разделенных кластеров.

---

7. Кластеризация HDBSCAN

5.1 Параметры и результат

HDBSCAN применён к поведенческим признакам (29 категорий) без добавления демографии.

Параметр	Значение
Найдено кластеров	**15**
Абонентов в шуме (кластер −1)	**13 178** (**39,4%**)
Абонентов в кластерах	20 268 (60,6%)

5.2 Метрики качества

Метрика	На нешумовых точках	На всех точках
Silhouette	0,437	**0,023**
Calinski-Harabasz	9 427,1	**312,2**
Davies-Bouldin	0,821	**3,67**

Важное замечание: Метрики, вычисленные только на нешумовых точках (0,437), являются **некорректными** для оценки качества сегментации в целом. Они искусственно завышены, поскольку исключают 39,4% данных. Реальные метрики (по всем точкам) Silhouette = 0,023 — один из худших возможных результатов.

5.3 Профили топ-кластеров HDBSCAN

Наиболее крупные кластеры (из 15):

Кластер	Абонентов	Доминирующий интерес
0	6 285	Новости и СМИ (+0,053)
1	1 903	Кафе и рестораны (+0,057)
2	2 262	Недвижимость (+0,068)
3	652	Медицина и аптеки (+0,059), Недвижимость (+0,055)
4	600	Игры (+0,076)
5	877	Одежда (+0,077)
6	475	Медицина и аптеки (+0,064), Книги (+0,059)
7	2 040	Медицина и аптеки (+0,073)
8	881	Дом и сад (+0,080)

Несмотря на наличие доминирующих категорий, отклонения от среднего составляют 0,05–0,08 — это крайне малые значения, что означает **статистически незначимое** разделение групп.

---

6. Анализ причин неудовлетворительных результатов

6.1 Синтетические данные

С большой долей уверенности можно утверждать, что данные синтетические, поэтому нарушена или отсуствует смысловую связь между поведением пользователя и его интересами, поэтому:

- поведенческий вектор каждого абонента представляет собой **случайную смесь несвязанных категорий**;
- профили всех 33 446 абонентов статистически неотличимы;
- матрица признаков является близкой к белому шуму.

6.2 Признаки

- PCA объясняет лишь 58,6% дисперсии при 15 компонентах из 30 — признаковое пространство не имеет выраженных направлений разброса.
- Малые абсолютные отклонения профилей кластеров от среднего (0,03–0,08) подтверждают однородность данных.
- Высокая доля шума в HDBSCAN (39,4%) — свидетельствует об отсутствии плотных областей.

---

7. Выводы

1. **Кластерная структура не обнаружена.** Оба алгоритма (KMeans: Silhouette = 0,04; HDBSCAN: Silhouette = 0,023) дают результаты, характерные для случайных данных без выраженных групп.
2. **Причина — синтетическая природа данных.** Случайное присвоение категорий сайтам лишает поведенческие признаки смыслового содержания, делая профили абонентов статистически неразличимыми.
3. **Формальная сегментация возможна, но не осмыслена.** KMeans с k=5 даёт разбиение с красивыми названиями («Активный образ жизни», «Здоровье и питание»), однако отклонения от среднего (< 0,05) статистически незначимы — кластеры не несут реальной информации для бизнеса.
4. **Задача принципиально решаема** — но только на реальных данных, где категории сайтов отражают истинные интересы пользователей.